Questions d'entretien : Data Science, Machine Learning et Deep Learning

Sommaire

- Fondamentaux du Machine Learning
- Analyse exploratoire des données
- Préparation des données
- Régression
- Classification
- Apprentissage non supervisé
- Deep Learning
- Réseaux de neurones convolutifs (CNN)
- Transfer Learning
- Fine-tuning
- Apache Airflow

Fondamentaux du Machine Learning

Concepts de base

- Quelle est la différence entre régression et classification ?
- Quelle est la différence entre apprentissage supervisé et non supervisé ?
- Qu'est-ce que la variable cible et que sont les variables explicatives ?
- Qu'est-ce qu'une régression linéaire ?
- Quelle est la forme générale d'une régression linéaire ?
- Que représentent l'ordonnée à l'origine et les coefficients du modèle ?
- Quelle est la différence entre un paramètre et un hyperparamètre ?
- Quelle est la différence entre la phase d'entraînement et la phase de prédiction ?

Analyse exploratoire des données

Concepts de base

- Qu'est-ce que l'analyse exploratoire des données ? À quoi sert-elle ?
- Quelle est la différence entre analyse univariée, bivariée et multivariée ?
- Pourquoi visualise-t-on les données avant de construire un modèle ?
- Comment choisir un graphique selon le type des variables (numérique ou catégorielle) ?

Analyse univariée : variable numérique

- Que montre un histogramme ? Comment l'interpréter ?
- Comment le nombre de classes (bins) influence-t-il la lecture d'un histogramme ?
- Comment lire la forme d'une distribution (symétrique, asymétrique à droite, asymétrique à gauche) ?
- Que montre une courbe de densité ? En quoi diffère-t-elle d'un histogramme ?

- Comment lire un boxplot (médiane, quartiles, moustaches, points isolés) ?
- Que révèle l'écart entre la moyenne et la médiane ?
- Quelles statistiques résument une variable numérique (moyenne, médiane, écart-type, minimum, maximum, quantiles) ?
- Que sont l'asymétrie (skewness) et l'aplatissement (kurtosis) ?
- Quelle transformation applique-t-on à une variable très asymétrique ?

Analyse univariée : variable catégorielle

- Que montre un diagramme en barres ?
- Que montre un diagramme circulaire ? Quelles sont ses limites ?
- Comment repérer une catégorie rare ou déséquilibrée ?
- Pourquoi faut-il être attentif au déséquilibre des classes de la variable cible ?

Analyse bivariée : deux variables numériques

- Que montre un nuage de points ?
- Comment lire la direction, la force et la forme d'une relation dans un nuage de points ?
- Comment reconnaître une relation linéaire, non linéaire ou absente ?
- Comment repérer des valeurs aberrantes ou des groupes dans un nuage de points ?
- Que signifie un nuage de points très dispersé autour de la tendance ?
- Qu'est-ce que le coefficient de corrélation de Pearson ? Quelles sont ses limites ?
- Pourquoi une corrélation proche de 0 n'implique-t-elle pas l'absence de relation ?
- Que montre une matrice de corrélation sous forme de carte de chaleur ?
- Comment lire une carte de chaleur de corrélation ? Que signifient les couleurs ?
- Comment repérer la multicolinéarité sur une carte de chaleur ?
- Que montre une matrice de nuages de points (pair plot) ?

Analyse bivariée : numérique et catégorielle

- Comment compare-t-on une variable numérique selon les catégories d'une autre variable ?
- Comment interpréter des boxplots côte à côte ?
- Comment interpréter des histogrammes ou des densités superposés par catégorie ?
- Que montre un diagramme en barres des moyennes par groupe ? Quelles sont ses limites ?
- Quel test statistique compare les moyennes de deux groupes ? De plus de deux groupes ?
- Que signifie un chevauchement important des distributions entre deux catégories ?

Préparation des données

Données manquantes

- Quelle est la différence entre suppression et imputation ?
- Quels sont les trois mécanismes de données manquantes ?
- Qu'est-ce que MCAR ?
- Qu'est-ce que MAR ?
- Qu'est-ce que MNAR ?
- Quelle est la différence entre MAR et MNAR ?
- Quand peut-on supprimer les lignes incomplètes sans risque ?

- Quels sont les inconvénients de l'imputation par la moyenne ?

Valeurs aberrantes et distributions

- Qu'est-ce qu'une valeur aberrante ? Comment la détecter et la traiter ?
- Qu'est-ce qu'une distribution normale ?
- Qu'est-ce qu'une distribution asymétrique ?
- Quand applique-t-on une transformation logarithmique à une variable ?

Corrélation et multicolinéarité

- Qu'est-ce que la corrélation ?
- Quelle est la différence entre corrélation positive et négative ?
- Que signifie une corrélation proche de 0 ?
- Quelle est la différence entre corrélation et causalité ?
- Qu'est-ce que la multicolinéarité ? Pourquoi pose-t-elle problème ?

Encodage et mise à l'échelle

- Pourquoi faut-il encoder les variables catégorielles ?
- Quelle est la différence entre encodage ordinal et encodage one-hot ?
- Qu'est-ce que le piège des variables indicatrices ?
- Quelle est la différence entre normalisation et standardisation ?
- Pourquoi la mise à l'échelle est-elle importante pour la descente de gradient ?

Découpage des données

- Pourquoi sépare-t-on les données en jeu d'entraînement et jeu de test ?
- À quoi sert un jeu de validation ?

Régression

Descente de gradient

- Quel est le principe de la descente de gradient ?
- Qu'est-ce que la fonction de coût ?
- Qu'est-ce que le gradient ?
- Quelle est la règle de mise à jour des paramètres à chaque itération ?
- Qu'est-ce que le taux d'apprentissage ?
- Que se passe-t-il si le taux d'apprentissage est trop grand ? Trop petit ?
- Quelle est la différence entre une itération et une époque ?
- Quand arrête-t-on la descente de gradient ?
- Quelle est la différence entre descente de gradient batch, stochastique et mini-batch ?
- Que faire si le coût augmente au lieu de diminuer ?

Hyperparamètres

- Qui fixe la valeur d'un hyperparamètre ?
- Donnez des exemples d'hyperparamètres de la descente de gradient.

- Pourquoi ne faut-il jamais utiliser le jeu de test pour régler les hyperparamètres ?
- Comment fonctionne la recherche par grille ?
- Comment fonctionne la recherche aléatoire ?
- Pourquoi teste-t-on souvent le taux d'apprentissage sur une échelle logarithmique ?
- Quel est le lien entre validation croisée et réglage des hyperparamètres ?

Métriques d'évaluation

- Pourquoi évaluer un modèle de Machine Learning ?
- Que mesurent la MAE, la MSE et la RMSE ? Quelles sont leurs différences ?
- Quelle métrique est la plus sensible aux valeurs aberrantes ?
- Que représente le coefficient R^2 ? Comment l'interpréter ?
- Un R^2 peut-il être négatif ? Que signifie-t-il ?

Surapprentissage et fuite de données

- Qu'est-ce que l'overfitting ?
- Qu'est-ce que l'underfitting ?
- Quelle est la différence entre overfitting et underfitting ?
- Qu'est-ce que le compromis biais-variance ?
- Comment réduire l'overfitting ?
- Qu'est-ce que le Data Leakage ?
- Pourquoi le Data Leakage donne-t-il une évaluation trompeuse ?

Régularisation

- Pourquoi régulariser un modèle de régression ?
- Quelle est la différence entre Ridge et Lasso ?
- Que contrôle l'hyperparamètre de régularisation ?
- Quelle méthode permet de supprimer automatiquement des variables ?

Classification

Concepts de base

- Qu'est-ce que la classification ? Quelle est la différence entre classification binaire, multiclasse et multilabel ?
- Qu'est-ce qu'une frontière de décision ?
- Quelle est la différence entre un modèle discriminatif et un modèle génératif ?
- Qu'est-ce que la régression logistique ? Pourquoi porte-t-elle le nom de régression ?
- Quel est le rôle de la fonction sigmoïde ?
- Qu'est-ce que la fonction softmax et dans quel cas l'utilise-t-on ?
- Qu'est-ce que le seuil de décision ? Comment influence-t-il les prédictions ?
- Quelle est la différence entre une probabilité prédite et une classe prédite ?
- Quelle est la différence entre les stratégies un-contre-tous et un-contre-un ?
- Qu'est-ce que l'entropie croisée (log loss) ?
- Pourquoi n'utilise-t-on pas l'erreur quadratique moyenne en classification ?

Algorithmes

- Comment fonctionne un arbre de décision ?
- Qu'est-ce que l'indice de Gini et l'entropie ? À quoi servent-ils ?
- Qu'est-ce que le gain d'information ?
- Comment fonctionne l'algorithme des k plus proches voisins ? Quel est l'effet de k ?
- Qu'est-ce qu'un SVM ? Que représentent la marge et les vecteurs de support ?
- Qu'est-ce que l'astuce du noyau (kernel trick) ?
- Quelle est la différence entre une marge dure et une marge souple ?
- Quelle est la différence entre bagging et boosting ?
- Pourquoi une forêt aléatoire généralise-t-elle mieux qu'un arbre seul ?
- Comment fonctionne le boosting de gradient ?

Métriques d'évaluation

- Qu'est-ce qu'une matrice de confusion ?
- Que représentent les vrais positifs, faux positifs, vrais négatifs et faux négatifs ?
- Que mesurent l'exactitude (accuracy), la précision, le rappel et le F1-score ?
- Pourquoi l'exactitude peut-elle être trompeuse ?
- Quel est le compromis entre précision et rappel ?
- Dans quels cas privilégie-t-on la précision ? Dans quels cas le rappel ?
- Qu'est-ce que la courbe ROC ? Que mesure l'AUC ?
- Quelle est la différence entre la courbe ROC et la courbe précision-rappel ?
- Quelle est la différence entre moyenne macro, micro et pondérée ?

Déséquilibre des classes et bonnes pratiques

- Qu'est-ce qu'un jeu de données déséquilibré ? Pourquoi pose-t-il problème ?
- Quelles sont les approches pour traiter le déséquilibre des classes ?
- Quelle est la différence entre sur-échantillonnage et sous-échantillonnage ?
- Comment fonctionne SMOTE ?
- Qu'est-ce que la pondération des classes ?
- Pourquoi la validation croisée stratifiée est-elle importante ?
- Qu'est-ce que le surapprentissage en classification ? Comment le détecter ?
- Qu'est-ce que la calibration des probabilités ?
- Comment choisir le seuil de décision optimal ?
- Quelle est la différence entre erreur de type I et erreur de type II ?

Apprentissage non supervisé

Concepts de base

- Qu'est-ce que l'apprentissage non supervisé ? Quels sont ses principaux types de tâches ?
- Quelle est la différence entre clustering, réduction de dimension et détection d'anomalies ?
- Pourquoi est-il difficile d'évaluer un modèle non supervisé ?
- Qu'est-ce que l'apprentissage semi-supervisé ?
- Qu'est-ce que la malédiction de la dimension ?

- Pourquoi la mise à l'échelle des variables est-elle cruciale en clustering ?

K-means

- Comment fonctionne l'algorithme K-means ?
- Qu'est-ce que l'inertie ?
- Pourquoi K-means dépend-il de l'initialisation ? Comment y remédier ?
- Comment choisir le nombre de clusters ?
- Qu'est-ce que la méthode du coude ?
- Qu'est-ce que le coefficient de silhouette ?
- Quelles sont les limites de K-means ?
- Pourquoi K-means est-il sensible aux valeurs aberrantes ?

Autres méthodes de clustering

- Comment fonctionne le clustering hiérarchique ? Quelle est la différence entre approche ascendante et descendante ?
- Qu'est-ce qu'un dendrogramme ?
- Comment fonctionne DBSCAN ? Que représentent ses deux hyperparamètres ?
- Quelle est la différence entre points centraux, points de bordure et points de bruit ?
- Quels sont les avantages de DBSCAN par rapport à K-means ?
- Que mesurent l'indice de Davies-Bouldin et l'indice de Calinski-Harabasz ?
- Comment interpréter et valider des clusters en pratique ?

Réduction de dimension

- Pourquoi réduit-on la dimension des données ?
- Qu'est-ce que l'analyse en composantes principales ?
- Que représentent les composantes principales et la variance expliquée ?
- Comment choisir le nombre de composantes à conserver ?
- Quelles sont les limites de l'ACP ?
- Quelle est la différence entre ACP et sélection de variables ?

Deep Learning

Concepts de base

- Qu'est-ce que le Deep Learning ? En quoi diffère-t-il du Machine Learning classique ?
- Quand préfère-t-on le Deep Learning à un modèle classique ? Quand l'évite-t-on ?
- Qu'est-ce qu'un neurone artificiel ?
- Qu'est-ce qu'un perceptron ? Quelles sont ses limites ?
- Qu'est-ce qu'un perceptron multicouche ?
- Que représentent les poids et les biais ?
- Quelle est la différence entre couche d'entrée, couches cachées et couche de sortie ?
- Pourquoi a-t-on besoin de fonctions d'activation ?
- Que se passerait-il sans fonction d'activation non linéaire ?
- Quelles sont les différences entre sigmoïde, tanh, ReLU et softmax ?
- Qu'est-ce que le problème du ReLU mourant ? Comment y remédier ?

- Quelle fonction d'activation choisit-on pour la couche de sortie selon la tâche ?

Entraînement

- Qu'est-ce que la propagation avant ?
- Qu'est-ce que la rétropropagation du gradient ?
- Quelles fonctions de coût utilise-t-on en régression ? En classification ?
- Qu'est-ce qu'une époque, un batch et une itération ?
- Quelle est l'influence de la taille du batch sur l'entraînement ?
- Qu'est-ce que le problème de la disparition du gradient ? Et de l'explosion du gradient ?
- Comment l'initialisation des poids influence-t-elle l'entraînement ?
- Qu'est-ce que le momentum ?
- Quelle est la différence entre SGD, RMSprop et Adam ?

Régularisation et généralisation

- Comment détecte-t-on le surapprentissage d'un réseau de neurones ?
- Qu'est-ce que le dropout ? Comment fonctionne-t-il ?
- Qu'est-ce que l'arrêt précoce (early stopping) ?
- Qu'est-ce que la régularisation L1 et L2 (weight decay) dans un réseau ?
- Qu'est-ce que la normalisation par batch ? Quels avantages apporte-t-elle ?
- Qu'est-ce que l'augmentation de données ?
- Pourquoi les réseaux profonds nécessitent-ils beaucoup de données ?
- Quelle est la différence entre un réseau dense et un CNN ?

Réseaux de neurones convolutifs (CNN)

Concepts de base

- Qu'est-ce qu'un réseau de neurones convolutif ? Pour quel type de données est-il conçu ?
- Pourquoi un réseau dense est-il mal adapté aux images ?
- Qu'est-ce qu'une opération de convolution ?
- Qu'est-ce qu'un filtre (noyau) ? Que détecte-t-il ?
- Qu'est-ce qu'une carte de caractéristiques (feature map) ?
- Qu'est-ce que le pas (stride) ? Quel est son effet sur la taille de la sortie ?
- Qu'est-ce que le remplissage (padding) ? Quelle est la différence entre « same » et « valid » ?
- Comment calcule-t-on la taille de la sortie d'une couche de convolution ?

Couches et architecture

- Qu'est-ce que le pooling ? Quelle est la différence entre max pooling et average pooling ?
- Pourquoi utilise-t-on le pooling ?
- Quel est le rôle de la fonction d'activation après une convolution ?
- Quelle est la structure typique d'un CNN ?
- Que fait la couche d'aplatissement (flatten) ?
- Quel est le rôle des couches entièrement connectées en fin de réseau ?
- Qu'est-ce que le global average pooling ? Quel avantage apporte-t-il ?
- Qu'est-ce qu'une convolution 1×1 ? À quoi sert-elle ?

- Qu'est-ce qu'une convolution séparable en profondeur ?
- Que représentent les canaux d'une image ?
- Comment les couches successives apprennent-elles des caractéristiques de plus en plus abstraites ?

Tâches en vision par ordinateur

- Quelle est la différence entre classification d'images, détection d'objets et segmentation ?
- Quelle est la différence entre segmentation sémantique et segmentation d'instances ?
- Qu'est-ce que l'intersection sur union (IoU) ?
- Qu'est-ce que la suppression des non-maxima (NMS) ?
- Quelle est la différence entre YOLO et les détecteurs en deux étapes ?

Transfer Learning

Concepts de base

- Qu'est-ce que le transfer learning ?
- Pourquoi le transfer learning est-il utile quand on a peu de données ?
- Qu'est-ce qu'un modèle pré-entraîné ?
- Pourquoi les premières couches d'un CNN sont-elles réutilisables d'une tâche à l'autre ?
- Quelle est la différence entre les couches générales et les couches spécifiques à la tâche ?
- Qu'est-ce que la tâche source et la tâche cible ?
- Quelle est la différence entre transfer learning et entraînement à partir de zéro ?

Stratégies

- Qu'est-ce que l'extraction de caractéristiques (feature extraction) avec un modèle pré-entraîné ?
- Qu'est-ce que le gel des couches (freezing) ?
- Quelle stratégie adopter quand le nouveau jeu de données est petit et proche du jeu source ?
- Quelle stratégie adopter quand le nouveau jeu de données est grand et très différent du jeu source ?
- Qu'est-ce qu'une tête de classification ? Pourquoi la remplace-t-on ?
- Pourquoi utilise-t-on un taux d'apprentissage faible avec un modèle pré-entraîné ?
- Qu'est-ce que le transfert négatif ?

Fine-tuning

Concepts de base

- Qu'est-ce que le fine-tuning ?
- Quelle est la différence entre le fine-tuning et le transfer learning ?
- Quelle est la différence entre fine-tuning et extraction de caractéristiques ?
- Quand faut-il faire du fine-tuning plutôt que de garder le modèle gelé ?
- Quelle est la différence entre fine-tuning complet et fine-tuning partiel ?
- Quelles couches dégèle-t-on en premier, et pourquoi ?
- Pourquoi procède-t-on souvent en deux phases : d'abord la tête, puis les couches profondes ?

Apache Airflow

Concepts de base

- Qu'est-ce qu'Apache Airflow et à quoi sert-il ?
- Qu'est-ce que l'orchestration de workflows ? En quoi diffère-t-elle de l'exécution d'un simple script ?
- Pourquoi utiliser un orchestrateur plutôt qu'une tâche planifiée classique (cron) ?
- Qu'est-ce qu'un DAG ? Que signifie chacune des lettres de l'acronyme ?
- Pourquoi un DAG ne doit-il pas contenir de cycle ?
- Qu'est-ce qu'une tâche (task) ?
- Qu'est-ce qu'un opérateur ? Quelle est la différence entre un opérateur et une tâche ?
- Quelle est la différence entre un opérateur, un capteur (sensor) et un hook ?
- Comment définit-on les dépendances entre les tâches ?
- Pourquoi dit-on qu'Airflow suit le principe « workflows as code » ?

Architecture

- Quels sont les principaux composants d'Airflow ?
- Quel est le rôle du scheduler ?
- Quel est le rôle de l'executor et des workers ?
- Quel est le rôle du serveur web (interface utilisateur) ?
- Qu'est-ce que la base de métadonnées et que contient-elle ?
- Quelle est la différence entre les executors Local, Celery et Kubernetes ?

Exécution et planification

- Qu'est-ce qu'une exécution de DAG (DAG run) ? Quelle est la différence avec une instance de tâche ?
- Quels sont les états possibles d'une tâche ?
- Comment planifie-t-on un DAG ? Qu'est-ce qu'une expression cron ou un intervalle de planification ?
- Qu'est-ce que la date logique (logical date) ? Pourquoi prête-t-elle souvent à confusion ?
- Qu'est-ce que le catchup ? Quand faut-il le désactiver ?
- Qu'est-ce que le backfill ?
- Qu'est-ce que l'idempotence d'une tâche ? Pourquoi est-elle importante ?
- Comment Airflow gère-t-il les échecs ? Que sont les tentatives (retries) et le délai entre deux tentatives ?
- Que sont les règles de déclenchement (trigger rules) ?

Communication et configuration

- Qu'est-ce que XCom ? Quelles sont ses limites ?
- Quelle est la différence entre une variable et une connexion ?
- Pourquoi ne faut-il pas stocker de secrets directement dans le code d'un DAG ?
- Qu'est-ce qu'un pool ? À quoi sert la notion de parallélisme et de concurrence ?
- Qu'est-ce que le templating avec Jinja dans Airflow ?

Airflow et Machine Learning

- Pourquoi Airflow est-il utile dans un projet de Machine Learning ?
- Quelles étapes d'un pipeline ML peut-on orchestrer avec Airflow ?

- Comment planifier le réentraînement périodique d'un modèle ?
- Quelle est la différence entre un pipeline de données (ETL / ELT) et un pipeline de Machine Learning ?
- Airflow est-il fait pour le traitement de données en streaming ? Pourquoi ?